


PROJET SYNTHÈSE - INDUSTRIE 4.0

Prédiction de la qualité de production d'une machine de torréfaction

Antoine VADOT & Mamadou Moctar BA

Pourquoi prédire la qualité ?



La machine


Une machine de torréfaction industrielle composée de capteurs (température, humidité) qui mesurent en continu, à la minute.

Aujourd'hui

Aujourd'hui, la qualité n'est mesurée qu'une fois par heure : on la constate trop tard pour agir sur le procédé.

Enjeux I4.0


Exploiter la donnée capteur pour anticiper la qualité au lieu de seulement la constater.

The slide features a dark gray background with three large, semi-transparent orange circles. One circle is in the top-left corner, another is in the bottom-left corner, and a third is in the bottom-right corner.

PROBLÉMATIQUE

Comment optimiser la qualité d'une production de café torréfié grâce aux données capteurs ?

La machine de torréfaction



Intervalle de mesure des capteurs : 1 minute
Intervalle de mesure de la qualité : 1 heure

Le dataset

2,1 M

relevés capteurs

échelle minute

+29 000

mesures qualité

échelle heure

5 × 3

sondes température

5 chambres × 3 capteurs

+ 2

Capteurs additionnels

Hauteur (H) & humidité absolue (AH)

Source : Kaggle - podsyp/production-quality

Variables & variable cible

Variables de températures

Unité : Fahrenheit

Plage : [150 ; 600]

Valeurs illogiques : Oui

Valeurs manquantes : Non

Variable d'humidité

Unité : %

Plage : [2.9 ; 11.8]

Valeurs illogiques : Non

Valeurs manquantes : Non

Variable d'hauteur

Unité : Centimètre

Plage : [141 ; 208]

Valeurs illogiques : Non

Valeurs manquantes : Non

Variable de qualité

Unité : ?

Plage : [221 ; 505]

Valeurs illogiques : Non

Valeurs manquantes : Non

Importation & Nettoyage des données

1. Capteur isolé défaillant : si un capteur s'écarte de > 50 de ses deux voisins de chambre, il est remplacé par leur moyenne.

➡ On corrige la donnée au lieu de supprimer toute la ligne

2. Les Températures illogique restantes sont supprimées : bornées (150 – 600).

3. Suppression des cases vides d'origine (NaN).

Exemple :

Capteur 1 : 850°C ⚠

Capteur 2 : 210°C

Capteur 3 : 212°C

→ **Capteur 1 corrigé = 211°**

(moyenne des 2 voisins)

Alignement temporel

Objectif: synchroniser des capteurs à la MINUTE avec une qualité à l'HEURE.

Données brutes

1 ligne = 1 minute

1 h = 60 min

date_time	T ₁	T ₂	T ₃	...	H
09:00	205	210	207	...	47
09:01	206	209	208	...	47
09:02	204	211	206	...	47
⋮	⋮	⋮	⋮	⋮	⋮
09:59	207	210	205	...	47

mise en matrice



Process matrix



1 ligne = 1 heure

heure	T ₁ ·m ₀	T ₁ ·m ₁	...	T ₁ ·m ₅₉	T ₂ ·m ₀	...	quality
09 h	205	206	...	210	204	...	82,5
10 h	205	206	...	210	204	...	79,1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮


1 capteur × 1 minute = 1 colonne

cible à prédire

Corrélation capteurs ↔ qualité



Sélection de variables (Pareto)




- Reduction de 17 à 13 capteurs.
- Même performance avec moins de capteurs → argument écologique / coût.


Premiers modèles :

Après normalisation de la variable « Qualité »

Comparaison des modèles



Autocorrélation de la qualité



quality(t) vs quality(t-n)

t-1 : 0,96


t-2 : 0,90

t-3 : 0,81

t-6 : 0,55

t-24 : 0,03

→ le passé proche prédit fortement le présent



Recherche d'hyperparamètres

- Optimisation menée sur XGBoost.
- On optimise aussi le nombre de lags : meilleur = 2.

Hyperparamètre	Valeur
n_lags	2
learning_rate	0,021
max_depth	6
subsample	0,59
colsample_bytree	0,82
min_child_weight	4
n_estimators	1306
gamma	2,42

Modèle final - XGBoost optimisé

R²


0,976

MAE

1.91 → 5,09


RMSE

2,58





Qualité réelle	Qualité Prédite	Écart
48,24	47,96	0,28
52,11	54,22	-2,11
95,07	94,69	0,38
43,66	47,61	-3,95
78,17	78,26	-0,09
42,25	42,03	0,22
75,00	74,32	0,68
61,27	60,38	0,89
82,04	81,72	0,32

De la régression à 5 classes de qualité



Le facteur clé : la chambre C3

80% du pouvoir prédictif concentré sur la chambre C3 (250°C)



Et si la qualité était interprétable ?

Même démarche, appliquée à un cas où la qualité a un sens concret.

Sur la torréfaction, la qualité n'a pas d'unité : impossible de traduire un $R^2 = 0,976$ en gain réel.

On a donc rejoué le même pipeline (**nettoyage** → **features** → **XGBoost**) sur le dataset Wine Quality, où la qualité est une note de dégustation de 0 à 10.

67 %

Note exacte prédite

96 %

Prédiction à ± 1 point

Et si la qualité était interprétable ?

Même démarche, appliquée à un cas où la qualité a un sens concret.

Variables clés d'un bon vin (note ≥ 8)

Variable	Valeur idéale	Unité	Importance modèle
Alcool (alcohol)	12	% vol.	14,2%
Acidité volatile (volatile acidity)	0,28	<i>g/L (acide acétique)</i>	9,2%
SO ₂ libre (free sulfur dioxide)	34	<i>mg/L</i>	7,7%
Densité (density)	0,99	<i>g/cm³</i>	7,6%

Planning prévisionnel

Planning	S1			S2				S3					S4					S5	
	20-avr	21-avr	22-avr	04-mai	05-mai	06-mai	07-mai	18-mai	19-mai	20-mai	21-mai	22-mai	01-juin	02-juin	03-juin	04-juin	05-juin	08-juin	09-juin
Phase 0 - Cadrage & exploration																			
Choix du Sujet																			
Creation du depot Github																			
Exploration des données																			
Redaction planning prévisionnel																			
1er imports des datas + identification nettoyage																			
Redaction livrable intermediaire n°1																			
Phase 1 - Préparation des données																			
1er nettoyage des données																			
Formatage / Standardisation / Normalisation																			
Phase 2 - Feature engineering & fusion des données																			
Création variables (Moy, Min, Max, std) par heure																			
Jointure des deux datasets sur datetime																			
Redaction livrable intermediaire n°2																			
Phase 3 - Sélection du modèle																			
Analyse de corrélation																			
Choix des variables																			
Calcul Baseline (RL, RF...)																			
Comparaison MAE, RMSE, R ²																			
Sélection du modèle																			
Redaction livrable intermediaire n°3																			
Phase 4 - Optimisation & évaluation du modèle final																			
Entrainement du modèle sélectionné																			
Optimisation des hyperparamètres																			
Comparaison MAE, RMSE, R ²																			
Redaction livrable intermediaire n°4																			
Phase 5 - Restitution & soutenance																			
Preparation Soutenance																			
Redaction livrable intermediaire n°5																			
Finalisation du projet																			
Soutenance																			

Difficultés rencontrées

Manque d'unité sur la variable « Qualité »

→ Impossible d'interpréter nos résultats



Références :

podsys. (s. d.). Production Quality [Jeu de données]. Kaggle.

<https://www.kaggle.com/datasets/podsys/production-quality/data>

alexkaggle95. (s. d.). Production Quality Prediction – MAE 6.954 [Code]. Kaggle.

<https://www.kaggle.com/code/alexkaggle95/production-quality-prediction-mae-6-954>

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009).

Wine Quality [Jeu de données]. UCI Machine Learning Repository.

<https://archive.ics.uci.edu/dataset/186/wine+quality>